

論文題目

connect4 を題材とした強化学習 AI の
判断の可視化

Visualization of Reinforcement Learning AI Decision
Making Using Connect4 as an Example

指導教授

萩原 将文 教授

慶應義塾大学 理工学部 情報工学科

令和 5 年度

学籍番号 62019277

村上 花恋

目次

あらまし	1
第1章 はじめに	2
第2章 関連研究	4
2.1 強化学習	4
2.1.1 ボードゲームへの応用	5
2.1.2 AlphaZero	6
2.1.3 ボードゲーム AI の問題点	10
2.2 XAI	10
2.2.1 概要	10
2.2.2 ボードゲームにおける XAI	13
2.2.3 contrastive explanation	14
2.2.4 importance	14
2.2.5 ボードゲーム学習支援	16
第3章 提案手法	18
3.1 提案手法のアルゴリズム	18
3.2 importance	22
第4章 評価実験	23
4.1 connect4	23
4.2 alphazero_baseline	24
4.3 データ実験	25
4.3.1 データセット	25

4.3.2	比較手法	25
4.3.3	評価指標	26
4.3.4	実験結果	27
4.3.5	考察 (データ実験)	27
4.4	システム実験	28
4.4.1	実験手順	28
4.4.2	評価指標	29
4.4.3	実験結果	30
4.4.4	考察 (システム実験)	33
第 5 章 結論		35
謝辞		36
参考文献		37
付録		41
付録 A データ実験の詳細		41
A.1	使用したモデルの詳細	41
A.2	対戦結果の詳細	41
A.3	評価指標の詳細	42
A.3.1	group count	43
A.3.2	stone count	43
A.4	データ実験における提案指標の計測	44
A.5	データ実験に使用したモデルの詳細	45
A.6	末尾のグループ化	45
A.7	グレーボックス的手法	46
付録 B 各種アルゴリズムの詳細		48
B.1	提案手法のアルゴリズム	48
B.2	比較手法のアルゴリズム	48

B.3	提案手法におけるニューロ補間	48
B.4	システム実験における提案手法の変更	53
付録 C	alphazero_baseline	55
C.1	ニューラルネットワーク	55
C.2	alphazero_baseline のパラメータ更新	56
付録 D	システム実験の詳細	59
D.1	被験者のデータ	59
D.2	第一段階	60
D.2.1	振り返りモード (GUI) の詳細	60
D.2.2	一日目	62
D.2.3	二日目	62
D.3	第二段階	62
D.4	質問項目の詳細	63
D.5	結果データ	63

あらまし

2024 年現在、チェス・囲碁・将棋などのメジャーな二人用ボードゲームにおいて AI は人間を遥かに凌駕するようになった。(ここは参考文献追加) しかし、AlphaZero[1] の登場から 5 年が経過した今もなおその十分な説明手法は登場していない。そこで本論文では AI の予測する進行図を複数提示することで AI の判断根拠の可視化を試みた。題材として対戦型ボードゲームの一つである connect4 を選択した。実験は AI 同士の対戦データを用いたデータ実験と被験者からのデータを用いたシステム実験の二種類を行った。結果としてデータ実験では提案手法が比較手法よりも高い予測精度を示し、システム実験では提案手法は？において比較手法よりも高い評価を得た。

第1章

はじめに

近年の AI 分野の発展は目覚ましく、画像分類や異常検知 (参考文献追加) などの単純なルールで記述する事が困難なタスクや、更には長らく人間に固有の技術であると考えられてきた画像や文章の生成の分野においてさえ、高い性能を発揮している。特に直近 3 年の Stable Diffusion[2]・Instruct GPT[3] の登場により、専門家でない人々が AI を使用する機会が増加した。そのため、人間と AI の将来的な関係性に対する考察の必要性が高まっているといえる。。(ここも参考文献追加?) この「優れた AI に対して人間はどう接するべきか」という命題を考える際には、既にスピードや能力において人間を大きく凌駕した AI を題材とし、手法の構築や実験を行うのが適当である。そのため、本論文では囲碁・将棋・チェスなどの主要なボードゲームにおいて人間の実力を凌駕したパフォーマンスを誇る AlphaZero[1] を題材に、説明性付与を試みる。

しかし、優れた AI が社会で広く実用化され受容されるためには、AI の出力が生み出される過程の透明性、信頼性の担保が必要不可欠である。説明性が必要とされるのは医療や金融などの判断の慎重さが求められるべき分野のみではない。上述の様に 2024 年現在、画像生成・文章生成 AI はオープンソース化され、広く普及した。そのような状況においても、G7 広島サミットでは国際的な協調の観点から AI の透明性を確保する重要性が指摘されている [4]。また、日本国内においても「信頼できる AI」を実現する必要性が認識されている [5]。それに加えて、将来的には「優れた AI に学ぶ」という探求心や学習意欲からも説明性へのニーズが広く湧き起こる事が予測される。現に囲碁・将棋・チェスなどの主要なボードゲームをオンラインでプレイできるサービスには、ゲーム終了

後の振り返り (感想戦) において AI の判断や AI による進行図を閲覧できるサービスが数多く提供されている。(ここに参考文献を入れる) 研究においてもボードゲームの学習支援という形で「AI に学ぶ」試みが存在する。しかし、後述するようにそれらの研究は各ゲームに特有の知識 (ドメイン知識) に依存するものが多い。

そこで本論文ではなるべくドメイン知識を用いず、AI の判断を可視化する手法を考案しその有効性を検証する。

続く第 2 章では関連研究について記載し、第 3 章では提案手法の詳細を述べ、第 4 章に行った 2 つの実験の結果と考察を記す。

第2章

関連研究

この章ではまず、既存のボードゲーム AI について AlphaZero を中心に強化学習の枠組みからその理論を説明する。次に AlphaZero の問題点について述べ、それを補完する既存手法、その課題について述べる。

2.1 強化学習

強化学習はタスクを選択をする主体と環境のやり取りとして定式化し、その相互作用から学習を行う形でタスクに取り組む分野である [6]。

強化学習タスクでは能動的に行動 a を行う主体と、主体が働きかける環境を設定する。図 2.1 に示すように環境の状況は状態 s として定義され、 s に対する行動 a によって環境の次の状態 $s' (= T(s, a))$ (T は遷移関数) と主体が獲得する報酬 r が決定されると仮定する。その仮定の下、環境から主体に与えられる報酬の合計 $G (= \sum r$ 以下収益と記載) を最大化することを目標とする。報酬を大きくするためには各状態 s に応じて適切な (より大きな報酬をもらえる可能性が高い) 行動を選択する必要がある。そのため状態 s に対して行動 a をとった場合の収益に対して見積もりをとり、見込まれる値が最も大きい行動を選択することでより大きな収益を獲得できると期待できる。このような収益の見積もりを $Q(s, a)$ とした場合、

$$a_m = \operatorname{argmax}_a Q(s, a) \quad (2.1)$$

となる a_m を選択することによって収益の最大化が期待される。また、状態 s から獲得できる収益の合計の予想値 $V(s)$ (以下状態価値関数と表記) は、最適な

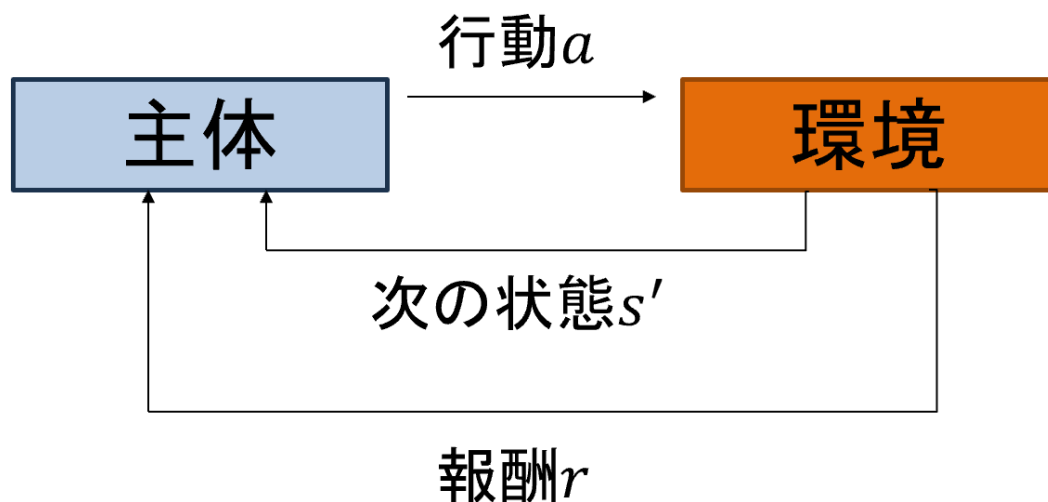


図 2.1: 強化学習

行動 a_m を取った場合の値として推定される。

$$V(s) = Q(s, a_m) (a_m = \operatorname{argmax}_a Q(s, a)) \quad (2.2)$$

強化学習手法によってタスクの最適化を図る際にはこの $V(s), Q(s, a)$ を正しく推定することが直接的な目標となる。 $V(s), Q(s, a)$ は主体が実際に環境とやり取りを行う(タスクを実行していく)中で改善されていくことが期待される。Temporary Difference 法や Monte Carlo 法等が基本的な $V(s), Q(s, a)$ の更新則であり、DQN[7] や Rainbow[8] 等はニューラルネットワークを使用して $V(s), Q(s, a)$ を推定することでより高い性能を発揮している。

2.1.1 ボードゲームへの応用

ボードゲームでは通例、状態 s は盤面の状況、行動 a はプレイヤーの選択、報酬 r はゲームの最後に勝敗として与えられる。図 2.2 に状態 s (ゲームの状況) と行動 a (プレイヤーの選択) によって盤面は次の状態 s' に遷移し、次の行動 a' (他のプレイヤーによる選択) を受け付ける、というサイクルとしてゲームの進行を定式化して表現することができる。また、上述した強化学習における状態価値関数 $V(s)$ の推定は「ある盤面はプレイヤーにとって勝利に近いのか」を表現し




図 2.2: ボードゲームにおける強化学習モデル

ていると解釈され、行動価値関数 $Q(s, a)$ は「ある盤面である行動をした場合のプレイヤーの勝率」を表していると解釈される。AlphaGo[9] や StockFish[10]、DeepLearningShogi[11] では状態 s は最新 N ステップの盤面と手数などのゲームのプレイにおいて重要な情報である。状態は行列等の形式に抽象化され、行動は次にプレイヤーが打つ箇所の座標となる。

また、図 2.3 に示すように本論文で使用した alphazero_baseline モデル [12] における入力は最新の盤面の状態を空白を 0, 先番 (赤) の石の位置を 1, 後番 (黄) の位置を -1 として抽象化した 6×7 の行列となる。また、後述する connect4 のルール上の制約により次にプレイヤーが打つ箇所 (行動) は列の数と同数の 7 種類に限定される。

2.1.2 AlphaZero

AlphaZero は 2016 年に登場し、囲碁の元世界チャンピオンであるイ・セドルに対して四勝一敗の成績を収めた AlphaGo の汎用版である。AlphaZero は先述の $V(s)$, $Q(s, a)$ を推定する際にニューラルネットワークと PV-モンテカルロ木探索アルゴリズムを使用する。




図 2.3: connect4 盤面の状態表現

2.1.2.0.1 ニューラルネットワーク AlphaZero におけるニューラルネットワークの構造を図 2.4 に示す。AlphaZero 内のニューラルネットワークに対する入力 は最新 8 ステップの盤面 ($\{s_{-7}, \dots, s_0\}$, s_{-i} は i ステップ前の盤面, s_0 は現在の盤面) であり、出力は方策 $P(\{s_{-7}, \dots, s_0\})$ と局面評価 $V(\{s_{-7}, \dots, s_0\})$ の二種類である。ネットワークは 1 つの畳み込み層と 20 の残差結合ネットワークで構成されている。方策は「現在の状況から次にどこを選択すべきか」を表現しており、次に選択すべき座標を確率分布の形式で表現する。方策内の値の大きさが AI によるその着手の評価と解釈され、成分が大きい座標を次に選択することが推奨される。また、局面評価 $V(\{s_{-7}, \dots, s_0\})$ は「(過去 8 ステップ分の状態を含めた) 現在の状況 s_0 は勝利に近いのか」を表現しており、値が上限に近ければ近い程、現在の状況 s_0 が次の着手を選択するプレイヤーにとっての勝利に近いことを表している。

2.1.2.0.2 PV-モンテカルロ木探索 PV-モンテカルロ木探索ではニューラルネットワークから得た方策 $P(s)$ (以下 $s = \{s_{-N+1}, \dots, s_0\}$ と表記する) と局面評価 $V(s)$ をシミュレーションによって改善する。PV-モンテカルロ木探索ではシミュレーションによって s または (s, a) (状態と行動の組) をノード、各行動 a を枝とした決定木を構築する。最終的に各ノード s から派生する各行動 $\{a_1, a_2, \dots, a_n\}$ の探索回数の分布 $N(s) (= N(s, a_1), N(s, a_2), \dots, N(s, a_n))$ が改善された方策と




図 2.4: AlphaZero ネットワークの構造

なる。一方、局面評価もまたモンテカルロ木探索により決定木が拡張されるなかで更新される。Algorithm12 に決定木と局面評価 $V(s)$ の詳細な更新アルゴリズムを示し、ここでは大まかな流れを示す。PV-MCTS のアルゴリズムの流れは以下である。

1. まず、探索の開始地点となるノード s を決定する。
2. 再帰部分では以下の処理を再帰的に呼び出す。
 - (a) ノード s を探索したことがない場合ニューラルネットワークから出力された方策 $P(s)$ と局面評価 $V(s)$ を返却する。
 - (b) ノード s を探索したことがある場合以下の puct スコア $U(s, a)$ と行動価値関数 $Q(s, a)$ の和に従い、子ノード s_c を選び、 s_c に対して再帰的に探索を行いその結果である $P(s_e), V(s_e)$ (s_e は再帰処理の結果た

どり着く決定木の端のノード)を返却する。 $(N(s), N(s, a))$ はそれぞれ $s, (s, a)$ に対して探索を行った回数)

$$U(s, a) = C(s)P(s, a)\frac{\sqrt{N(s)}}{1 + N(s, a)} \quad (2.3)$$

$$C(s) = \log \frac{1 + N(s) + C_{\text{base}}}{C_{\text{base}}} + C_{\text{init}}(C_{\text{base}}, C_{\text{init}} \text{ はハイパーパラメータ}) \quad (2.4)$$

このようなプロセスによって構築された決定木を用いてモデルは対戦を行う。

2.1.3 ボードゲーム AI の問題点

StockFish[10] や DeepLearningShogi[11](dlshogi は NN を使っている) の NN 無の将棋 AI に変える) などの従来のボードゲーム AI は設計がそのゲーム固有の知識 (ドメイン知識) に基づくものが多く、「ある条件を満たすときにある選択をする」と言ったようにその挙動をルールとして表すことが可能である。一方で AlphaZero のニューラルネットワークと木探索を組み合わせた手法では方策と局面評価の根拠を得ることができない。つまり AlphaZero の問題点として説明性の欠如が挙げられるのである。説明性の欠如は AI の判断に対する責任の不在を意味し、システムのよりハイレベル、ハイリスクなタスクへの実用化に対する妨げとなっている。

2.2 XAI

2.2.1 概要

XAI とは Explainable AI(説明可能 AI) の略語であり、AI を人間に対して説明可能なものにする、もしくは説明可能な AI を構築する領域である。(参考文献追加) 本研究は AI の判断根拠として先読みを示す面で XAI の分野に属する研究であると言える。ここでの「説明可能性」の語は「人間に理解できる形で説明を与える能力」[13] と定義され、

- いつ
- どのような
- どのように

説明を与えるかによってさらに細かく分類される。「いつ」、つまりどの時点で説明を与えるかに関しては既存のネットワークに対して新たに説明を加える「事後的」説明と初めから動作の根拠を示せるようにネットワークやシステムを構築する「事前的」説明に分類できる [13]。「どのような」、つまり説明の内容に

Algorithm 1 PV-MCTS in AlphaZero (Part 1: Exploration)



```

1:  $t$ : 決定木
2:  $T$ : 遷移関数
3:  $N(s, a)$ :  $(s, a)$  の組み合わせを探索した回数
4:  $Q(s, a)$ : 行動価値関数 ( $\text{Explore}(s)$  の平均)
5:  $W(s, a)$ : 行動価値の総和 ( $W(s, a) = Q(s, a)N(s, a)$ )
6:  $P(s, a)(= P(s_n), s_n = T(s, a))$ :
7: ニューラルネットワークから出力された方策
8:  $V(s, a)(= V(s_n), s_n = T(s, a))$ :
9: ニューラルネットワークから出力された局面評価
10: function EXPLORE( $s_{\text{start}}$ )
11:   Set  $s_{\text{now}} = s_{\text{start}}$  and  $a_{\text{now}} = a_m$ 
12:   for each simulation do
13:      $\zeta \leftarrow \text{emptylist}$ 
14:      $s_{\text{current}} \leftarrow s_{\text{start}}$ 
15:     while  $s_{\text{current}}$  がゲームの終了状態でない場合 do
16:        $a_t \leftarrow \text{TreePolicy}(s)$ 
17:       ( $T$  は遷移関数)
18:        $(s_{\text{current}}, a_t)$  を  $\zeta$  の末尾に追加
19:        $s_{\text{next}} \leftarrow T(s_{\text{current}}, a_t)$ 
20:        $s_{\text{current}} \leftarrow s_{\text{next}}$ 
21:     end while
22:      $G \leftarrow V(s_e)$ 
23:     ( $s_e$  は  $s_{\text{start}}$  から探索してたどり着いたノード  $s_e$ )
24:     BACKPROPAGATE( $\zeta, G$ )
25:   end for
26: end function

```

Algorithm 2 PV-MCTS in AlphaZero (Part 2: Backpropagation)

```

1: function TREEPOLICY( $s$ )
2:   if  $s$  が探索されていない子ノードを持つとき then
3:      $s_c \leftarrow T(s, a)$  ( $s_c$  は未探索のノード)
4:     INITNODE( $s_c$ )
5:       $a$ 
6:   else
7:     以下の PUCT スコア  $U(s, a)$  を計算
8:      $U(s, a) = C(s)P(s, a) \frac{\sqrt{N(s)}}{1+N(s, a)}$ 
9:      $C(s) = \log \frac{1+N(s)+C_{\text{base}}}{C_{\text{base}}} + C_{\text{init}}$ 
10:    ( $C_{\text{base}}, C_{\text{init}}$  はハイパーパラメータ)
11:    ( $N(s) = \Gamma N(s, a)$ )
12:    以下のように  $a$  を求める
13:     $a = \operatorname{argmax}_a (Q(s, a) + U(s, a))$ 
14:      $a$ 
15:   end if
16: end function
17: function BACKPROPAGATE( $\zeta, G$ )
18:   for each node-action pair  $(s, a)$  in  $\zeta$  do
19:      $N(s, a) \leftarrow N(s, a) + 1$ 
20:      $W(s, a) \leftarrow W(s, a) + G$ 
21:      $Q(s, a) \leftarrow \frac{W(s, a)}{N(s, a)}$ 
22:   end for
23: end function
24: function INITNODE( $s$ )
25:   for each action  $a$  from  $s$  do
26:      $N(s, a) \leftarrow 0$ 
27:      $W(s, a) \leftarrow 0$ 
28:      $Q(s, a) \leftarrow 0$ 
29:   end for
30: end function

```

については「大域的」説明と「局所的」説明の二つに分類される。「大域的」説明は行動 a を選択する主体（モデル）の全体的な方針について述べるものである一方で、「局所的」説明は主体（モデル）の個々の判断について説明する [14]。また、「どのように」、つまり説明を表現する形態としては saliency map[15], Grad-CAM[16] といった視覚的な可視化や、教師データと予測結果との関係の数値的な定量化 [17] が存在する。（もうちょい追加）本論文において構築するシステムは「事後的」「局所的」「視覚的」説明を提供する。

また、本論文は XAI 分野の中でも特に強化学習方面に対して説明を加える領域を XRL(Explainable Reinforcement learning) と呼ぶ。（余裕があったら追加、XRL の試みは様々な強化学習システムを対象とし、）

2.2.2 ボードゲームにおける XAI

McGrath ら [18] はチェスにおける人間の知識が AlphaZero にどれだけ反映されているかを訓練段階やネットワークの深さなどの多様な指標で調査した。他にも、Lee ら [19] による AI の着手に対してゲームの固有の知識（ドメイン知識）を用いたモデルの挙動に対する解説文の自動生成の試み等が存在する。しかし、このようなドメイン知識は必ずしも AI の挙動と相関が無いことも指摘されている [18]。AI による画像分類タスクの可視化手法として用いられていた saliency map[15] や Grad-CAM[16] を強化学習に用いる例も存在する [14][20][21]。しかしそれらのニューラルネットワークの活性を根拠とした指標は木探索部分との繋がりが弱く、最終的に決定木を用いて意思決定を行うシステムの動作根拠を直接的に説明できない。また、これらの画像分類用の手法は

- 本来ゲームに存在する時系列の要素を説明に含められない
- 時系列を無視してゲーム画面や盤面の一部を変更する必要がある

という問題点が存在する。

2.2.3 contrastive explanation

上述の問題点を解決するために、本論文の第4章におけるシステムでは AlphaZero が構築する決定木を用いた contrastive explanation (対象説明、比較説明) を提供する。contrastive explanation は事象を説明する方法論の1つであり、ある事象 a が起こった際にその理由を直接説明する代わりに「他の事象 \bar{a} が起こらなかった理由」を説明することで間接的にある事象 a の原因を説明するアイデアである [22]。Jacovi らの [22] では自然言語処理の分類タスクにおいて本来の入力データと編集された入力データの出力を比較することで、入力の中の部分がモデルの判断に寄与しているかを示している。Mishra らの [23] では医療タスクにおけるニューラルネットワークの判断を決定木に近似した上で AI の判断 a から派生する予想と別の判断 b から派生する予想を提示する形で AI による判断の妥当性を示している。(ロボット追加) また、Gajcin らの [24] では異なるモデルの挙動の違いをユーザーに示す目的で contrastive explanation が用いられている。これらの強化学習・木構造ネットワークに対する constrative explanation の手法は決定木上の「最も可能性が高い」「単一の」予想図を用いることを前提としている。そのため第3章でしめす提案手法では決定木上の複数の予想図を用いた constrative explanation の実現を試みた。図??に決定木ネットワークにおける contrasitive explanation のイメージを示している。

2.2.4 importance

ゲームやタスクにおいて勝負の分かれ目となりうる場面や、ミスをしやすい場面、危険な事故が起きやすい場面を特定することは非常に有用である。また、このような AI モデルが他の場面よりも重要度が高いと判断する状況を収集することは、モデルの挙動に対する効率的な調査を可能にする。Torryay ら [25] や Amir ら [26] は状態の重要度 $I(s)$ を一つ先の行動価値関数 $Q(s, a)$ が次の選択によって大きく左右されるような状態を重要度の高い局面として定義している。 $Q(s, a)$ の揺らぎの捉え方にはいくつかの方式が存在し、Torryay らは $I(s)$ を s か




図 2.5: contrastive explanation

ら辿り着きうる最善の $Q(s, a)$ と最悪の $Q(s, a)$ の差として定義している。

$$I(s) = \max Q(s, a) - \text{worst} Q(s, a) \quad (2.5)$$

Amir らは $I(s)$ を s から辿り着きうる最善の $Q(s, a)$ と二番目に値の大きい $Q(s, a)$ の差として定義している。

$$I(s) = \max Q(s, a) - \text{secondMax} Q(s, a) \quad (2.6)$$

しかし、これらの定義は imp が $Q(s, a)$ の値が低くなるような行動 a に大きく影響されるリスクや、図 2.6 のように状態に対称性があるような場合に重要度が小さくなってしまいうリスクがある。また、Guo ら [27] は重要度 I を収益 G が確定するまでの一連の流れ（エピソード）やエピソード内の時点 t の重要度を収益 G との関連度の大きさから多角的に定めている。しかし、Guo らの定義は状態の符号化や回帰などのデータの加工段階が多く、指標自体の説明性に疑問が残る。AI モデルに対して説明を加える際にはその手法自体もなるべく簡明である方が望ましいと考えられる。




図 2.6: ボードゲームにおける強化学習モデル

2.2.5 ボードゲーム学習支援

本論文は高度な AI の動作を人間に理解させることを目標としており、学習支援の側面を含んでいると言える。既存の AI を用いたボードゲーム学習支援システムとしては Lee ら [28] やオンラインサービスである DecodeChess[19] などによる解説文自動生成や、Richard[29] らや Richard[30] らの人間側の悪手を自動的に検知しその理由を個別に指摘するモデルが提案されている。しかし「ボードゲームに対する XAI」の段での内容と同様にその多くがゲームのドメイン知識に依存しており、指導の内容も人間の知識に依存したものになってしまうと

いう欠点がある。(参考文献追加)

第3章

提案手法

関連研究の章ではニューラルネットワークや決定木が内包する説明性の欠如という問題点と説明を加える既存手法の持つ課題について述べた。本論文ではそれらを踏まえた

- 本来ゲームに存在する時系列の要素を含む
- 評価基準が勝敗に直結する
- 人間のドメイン知識に依存しない

説明手法を提案する。図 3.1 に提案手法の概要を示している。本手法はある状態 s と行動 a の組に対して AI が予想する未来図 $o(s)$ とそこに至るまでの道筋の集合を取り出し、その傾向を見出すことによる AI の判断の意図を可視化を目標とする。

3.1 提案手法のアルゴリズム

本手法は AlphaZero システムのニューラルネットワークと木探索部分のうち、主に木探索の部分を対象に適用される。本手法では決定木の判断を説明する際に最も有用な部分を決定木から抽出することを主な目的としており、アルゴリズムはボードゲーム AI に留まらず決定木構造を持つ多くのシステムに応用可能である。アルゴリズムの流れは以下の通りである。図 3.2、図 3.3 はステップごとのアルゴリズムのイメージ図である。

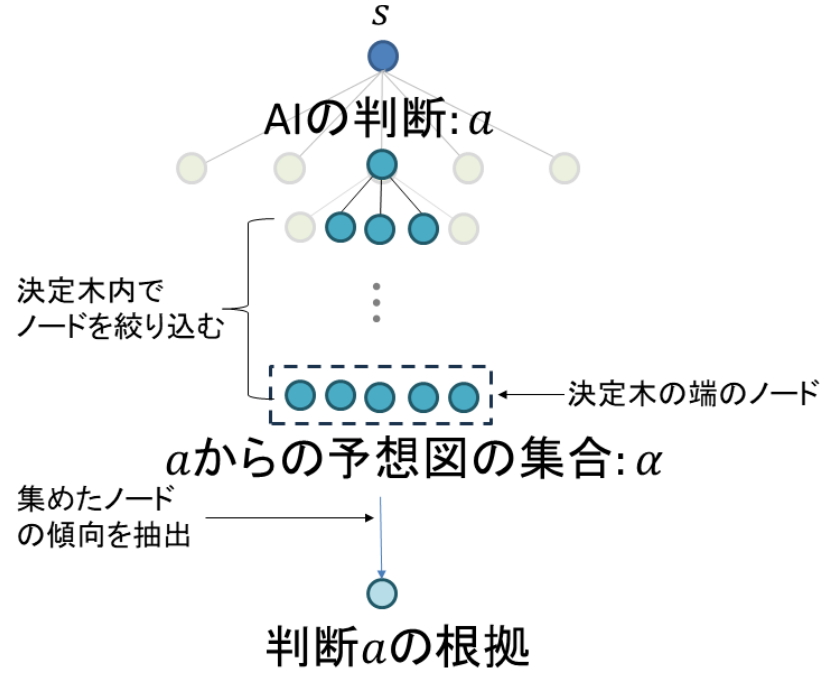


図 3.1: 提案手法の概要

1. 説明を付与する状態と行動の組 (s_{start}, a) を選択する。このとき注目している状態 s_{now}, a_{now} はそれぞれ

$$s_{now} = s_{start} \quad (3.1)$$

$$a_{now} = a \quad (3.2)$$

とする。

2. 以下の流れを l ステップ分繰り返す。

決定木中の注目しているノード s_{now} における訪問回数 $N(s_{now})$ 中の上位 k 個分の行動 $\{a_1, a_2, \dots, a_k\}$ (a_i は k 番目に有望な行動とする) を取り出す。

s_{now} から行動 $\{a_1, a_2, \dots, a_k\}$ を取ることでたどり着く各ノード $\{s_{next_1}, s_{next_2}, \dots, s_{next_k}\}$ ($s_{next_i} = T(s_{now}, a_i)$, T は遷移関数) に対して同様の操作を繰り返す。

3. 集めた k の l 乗個のノード $\{s'_1, s'_2, \dots, s'_{k^l}\}$ のそれぞれ s'_i ($i = 1, 2, \dots, k^l$) に

① (s_{start}, a) を決定

② 訪問回数上位のノードを収集




図 3.2: 提案アルゴリズムの概要 (step1~ 2)

対して以下の操作を再帰的に繰り返す。 s'_i における方策 $P(s'_i)$ 中の最も有望な行動 $a_{promising}$ と $s'_{next_i} = T(s'_i, a_{promising})$ を記録する。そのようにして記録した $\{s'_{next_1}, s'_{next_2}, \dots, s'_{next_{k^l}}\}$ のそれぞれ s'_{next_j} ($j = 1, 2, \dots, k^l$) にも同様の操作を盤面ノードが決定木の端に辿り着くまで行う。

4. step3 によってたどり着いた k^l 個のノードによる集合 $S = \{s_{edge_1}, s_{edge_2}, \dots, s_{edge_{k^l}}\}$ を任意の共通項 c によっていくつかの副集合 $\{S_1, S_2, \dots, S_q\}$ に分ける。
5. 共通項で括られた各集合 $\{S_1, S_2, \dots, S_q\}$ のうち、最も要素数が多いもの S_{max} 中の各要素 $\{s_{e_1}, s_{e_2}, \dots, s_{e_u}\}$ と各要素に対応する軌道 $\{\zeta_{s_{e_1}}, \zeta_{s_{e_2}}, \dots, \zeta_{s_{e_u}}\}$ を抽出する。

このアルゴリズムを要約すると、図 3.4 のようにある局面 s と行動 a の組み合わせから辿り着きやすい結末 $O(s, a)$ を抽出し、 $O(s, a)$ に至るまでの複数の

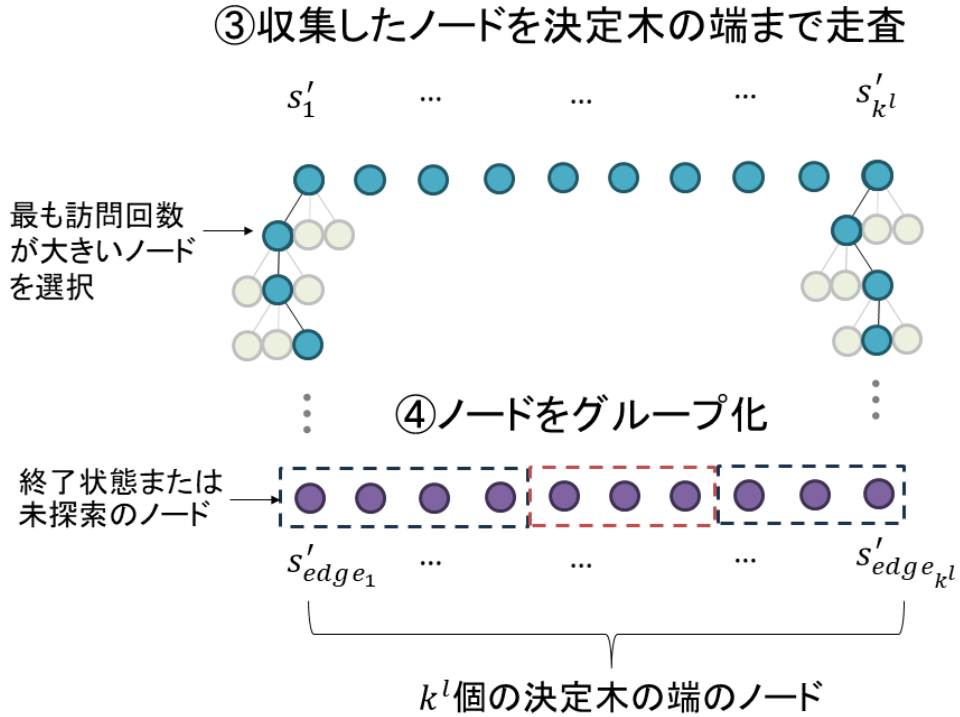


図 3.3: 提案アルゴリズムの概要 (step3~4)

道筋を抽出すると表現できる。調査を行う者が複数の道筋を観察できることで、共通する傾向や法則性を見出せるというメリットが存在する。これは第2章で述べたような最も可能性が高い一つの分岐を示す、といったような情報が単一である従来の手法には不可能である。提案手法の疑似コードは付録Bに記載している。

付録Aで示すように connect4 タスクにおいて収集される軌道の集合においては末端部分のいくつかの選択が共通している傾向が確認された。そのため状態と行動の組 (s, a) から $O(s, a)$ という結果を予測する過程で $O(s, a)$ から末尾の数手を取り除いた版面 d にたどり着く傾向の発見などの知識獲得が記載される。




図 3.4: 提案手法と既存手法

3.2 importance

前章で述べたように、エピソード中の各状態 s の重要度 $I(s)$ の定義を以下のように定めた。

$$I(s) = V[Q'](Q' = [\max Q(s, a), \text{secondMax} Q(s, a), \dots, \text{thirdQuantile} Q(s, a)]) \quad (3.3)$$

つまり、現在の状態 s に対する行動の集合 $A(= a_1, a_2, \dots, a_N)$ とした際の行動価値関数の集合 $Q(s, a_1), Q(s, a_2), \dots, Q(s, a_N)$ のうち値の大きさが上位 75 % の成分で構成される集合の分散として重要度 $I(s)$ を定義する。これは次の一手で辿り着きうる収益の予想の揺らぎの幅を意味しており、先述した盤面の対称性や悪い選択肢の影響が大きくなる可能性の軽減が期待できる。

第4章

評価実験

提案手法の有効性を示すため2種類の実験を行った。いずれもタスクの対象として connect4 を扱っている。一つ目の実験はコンピュータ同士の対戦データを用いて提案手法による想定図の妥当性の実証を試みた(以下データ実験と表記)。二つ目の実験は自作の connect4 学習支援システムを用いて提案手法のユーザーインタフェースを含んだ優位性の実証を試みた(以下システム実験と表記)。この章ではまず実験の際に用いたタスクである connect4 と使用したモデルである alphazero.baseline について述べる。そののちにデータ実験、システム実験の詳細と結果を記載する。

4.1 connect4

connect4[31] はボードゲームの一種である。ルールは五目並べに極めて近く、二人のプレイヤーが交互に互いの駒を盤上に置き、最終的に縦・横・もしくは斜めに連続して4つの石を並べたプレイヤーの勝利となる。ただし、五目並べや連珠との相違点として「重力」の存在が挙げられる。この「重力」とは各プレイヤーが石をボード上の最も下の行または既に置かれた石の上にしか置けないという規則を表している。そのため、各プレイヤーの選択肢はボードの列の数と等しい。connect4 の一般的なボードの広さは 6×7 であり 6×7 のコネクト4については1988年にAllis[32]により知識ベースの手法による先番勝利が証明された。Tromp[33]によるconnect4の $\alpha - \beta$ 木探索によって導かれた各盤面の最善手とそのデータも一般に公開されている。また、connect4は盤上に全ての




図 4.1: connect4

情報が開示されており、結果もどちらか一方の勝利または引き分けのみであるため 2 人ゼロ和完全情報ゲームに分類される。本論文の実験において提案手法を connect4 に適用する際には最終盤面において 4 つ以上並んでいる石の座標を特徴として用いた。

4.2 alphazero_baseline

alphazero_baseline[12] は alphaZero を connect4 用に簡易的に模したネットワークであり、入力は最新の盤面 s_0 、出力は 1×7 (7 はボードの列の数) の方策 $P(s)$ (以下 $s = s_0$ とする) とスカラー値の局面評価 $V(s)$ (値域は -1 から 1) である。方策は確率分布であり、要素の値が大きいインデックスを選択することで勝利に近づくと予想される。局面評価は入力に対する評価を表しており、1 が入力の




図 4.2: alphazero_baseline の入出力

手番のプレイヤーにとっての勝利、-1 が敗北の予想を表している。

4.3 データ実験

提案手法と後に述べる比較手法によるゲーム結果（後で勝敗も含める）の予測精度を比較した。

4.3.1 データセット

alphazero_baseline モデル同士の対戦データ 2000 局分 (盤面数:61049) を使用した。いずれもいずれも弱い AI が先番のデータを使用している。これは弱い AI が後番の場合評価関数の変動が極めて小さくなることと、弱い側が先番を選択することが指導において一般的とされるためである。

4.3.2 比較手法

提案手法と比較手法はそれぞれ以下の方式で予測を行う。比較手法の詳細なアルゴリズムは付録 B に記載した。




図 4.3: 提案手法と比較手法の比較

- 比較手法: 探索の開始地点から最も訪問回数が大きい選択枝を選び、決定木の端までたどり着いた際にそこで四つ繋がっている石の組み合わせ、位置を記録する。
- 提案手法: 集めた盤面における 4 つ繋がっている石を集計し、出現頻度が高い 4 つの個別の石の位置と出現頻度が高い二つの組み合わせを記録する。組み合わせを二つ記録する理由は下の図のように最終的に繋がっている組み合わせが二つある可能性を考慮するためである。

図 4.3 は比較手法の概要を示している。

4.3.3 評価指標

両手法による予測の精度を独自に定義した二つの定義 $\text{group count}(C_g)$ 、 $\text{stone count}(C_s)$ によって計測した。 stone count 、 group count の詳細な定義は付録 A に記載する。どちらも最終盤面において 4 つ以上連続して並ぶ石と組み合わせ (以下 fatal stone、fatal group と記載) の座標に対する予測精度を表している。ここでは概略を述べる。手法によって予測された fatal stone、fatal group の座標をそれぞれ F_s, F_g とする。

4.3.3.0.1 group count

予測の石の組み合わせ単位での精度を示しており、手法による予測 F_g と実際の fatal group の集合 R_g に共通する要素がある場合 1、無い場合は 0 となる。また、 F_g と R_g が両方とも空集合 ϕ である場合 (実際の結果が引き分けでありかつそれを正しく予測できている場合) group count は 1 となる。

4.3.3.0.2 stone count

予測の個別の石単位での精度を表しており、手法による予測 F_s と実際の集合 R_s の共通する要素の数を 4 で割った値である。値の最大値は 1 であり、先述の値が 1 を超える場合も stone count は 1 として扱う。group count と同様に F_s と R_s が両方とも空集合である場合 stone count は 1 となる。

4.3.4 実験結果

表 4.1 に実験結果を示す。いずれの場合も group count において提案手法は比較手法より高い値を示した。表中に記載した「補間」の詳細は付録 B に記載する。

表 4.1: 実験結果:データ実験

手数 (盤面数, 補間の有無)	group count		stone count	
	提案手法	比較手法	提案手法	比較手法
19-24(9862, 無)	0.60	0.43	0.55	0.62
19-24(9862, 有)	0.63	0.44	0.61	0.63
13-24(21022, 無)	0.52	0.37	0.55	0.56
13-24(21022, 有)	0.55	0.37	0.55	0.56

4.3.5 考察 (データ実験)

提案手法は group count において比較手法より高い結果を示した。この結果は提案手法が fatal group を予測する能力に長けている事を意味する。比較手法

によって予測される fatal group の集合は最も訪問回数が大きい分岐が辿り着く 1 つの最終状態のものである。一方で提案手法により予測される fatal group の集合は、複数の分岐がそれぞれに辿り着く最終状態の fatal group の多数派投票によって決定され、第 1 位と第 2 位のものが採用される。

使用した対戦データは対戦者間の強さに差があり、予測は強い側の決定木を用いている。決定木内での最も訪問回数の大きい分岐 (以下主分岐と記載) は AI が予測する双方が最善を尽くした場合の進行と解釈される。実際に弱い AI と対戦を行う際には、弱い AI は強い AI が最善とみなす行動 (最も訪問回数が大きい行動) を必ずしも選択しない。そのため、実際の進行は、比較手法に用いられる主分岐とは異なる可能性が高い。提案手法では、主分岐を含む複数の分岐を用いているため、より精度の高い予測が可能になったと考えられる。

また、提案手法は 2 組の fatal group を保存することから比較手法よりも予測する fatal group の数が増える傾向にあるため、必然的に group count の値も大きくなったとも考えられる。

4.4 システム実験

提案手法の人間に対する有効性を示すため以下のような自作した connect4 の学習支援システムを用いて実験を行った。実験対象者は計 22 人の 10 代-20 代学生 (男性 17 名:女性 5 名) となった。

4.4.1 実験手順

実験は被験者一人あたりにつき三回行われ、前半二回を第一段階 (提案手法による学習)、後半一回が第二段階 (被験者同士の対戦) とした。ここでは第一段階である提案手法の学習について述べる。

4.4.1.0.1 第一段階 (提案手法による学習)

提案システムを用いた学習はさらに




図 4.4: 開始画面

- AI システム (alphazero_baseline) との対戦
- 提案手法によるゲームの振り返り

の2ステップに分けられる。AI システムとの対戦が終了するとシステムは「振り返りモード」に移行する。ユーザーはゲームの任意の地点において提案手法または比較手法が提案する予想図を見ることができる。実験の際には被験者をグループ A(提案手法による予想図を見せるグループ) とグループ B(比較手法による予想図を見せるグループ) に分類した。数字が描かれたボタンは列のインデックスを表しており、各ボタンを押した際にその列を選択した場合の想定図と局面評価を確認できる。

4.4.2 評価指標

システム実験の評価指標は主観評価と客観評価の二つに分けられる。主観評価は被験者による五段階評価であり、「タスクの熟達度に関連する質問」((a)) と「タスクの楽しさ・面白さに関連する質問」((b)) の二つに分けられる。具体的な質問事項は付録 D に記載する。客観評価はグループ A(提案手法) の被験者とグループ B(比較手法) の被験者の対戦成績である。




図 4.5: 振り返り画面

4.4.3 実験結果

予想図で提示される先読みの手数ごとに主観評価の平均値 (1 ~ 5) を表 4.2 に示す。先読み手数が 3 手または先読み手数制限なしの場合に、提案手法は比較手法に対して高い結果を示した。

表 4.2: 先読み手数 3 手の場合

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.29	3.17
	振り返りによって AI の意図を掴むことができたと感じますか	2.43	2.67
	(二回目のみ) 一回目に比べて成長したと感じますか	2.75	4.33
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	3.71	3.67
	システムにより振り返りが楽しくなったと感じますか	3.57	3.60




図 4.6: 予想図の表示

表 4.3: 先読み手数 5 手の場合

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.00	4.00
	振り返りによって AI の意図を掴むことができたと感じますか	2.60	4.00
	(二回目のみ) 一回目に比べて成長したと感じますか	3.67	4.33
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.00	4.80
	システムにより振り返りが楽しくなったと感じますか	4.20	4.60

表 4.4: 先読み手数 7 手の場合

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.83	4.33
	振り返りによって AI の意図を掴むことができたと感じますか	2.67	3.67
	(二回目のみ) 一回目に比べて成長したと感じますか	2.75	4.33
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.17	4.67
	システムにより振り返りが楽しくなったと感じますか	3.00	3.50

表 4.5: 先読み手数制限なしの場合

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	4.25	4.00
	振り返りによって AI の意図を掴むことができたと感じますか	3.50	3.00
	(二回目のみ) 一回目に比べて成長したと感じますか	2.75	4.33
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.5	4.00
	システムにより振り返りが楽になったと感じますか	4.75	4.40

また、第二段階である被験者同士の対戦結果を表 4.6 に示す。付録 D に示すように被験者一人に対して二回対戦を行った。結果として示す score は勝利を 1, 敗北を -1, 引き分けを 0 とした二回の対戦の平均値として定義される。結果は表 4.6 に記載する。提案手法を用いて訓練を行ったグループ (A) は比較手法を用いて訓練を行ったグループ (B) よりも高い勝率を記録した。

表 4.6: 対戦の結果

グループ	score
A(提案手法)	0.25
B(比較手法)	-0.15

また、第三章で示した新たな重要度の定義 (式 3.3) の妥当性を検証するため、盤面 s の重要度 $I(s)$ と被験者が s の進行図を見た時間 t の相関を調査した。比較手法には式 2.6 の定義を用いた。結果を表 4.8 と示す。いずれの手法も t との有意な相関が見られなかった。

表 4.7: 重要度と t の相関

日数	提案手法	比較手法
1 日目	-0.035	-0.034
2 日目	-0.083	0.067

4.4.4 考察（システム実験）

提案手法を用いたグループ A がグループ B を上回る評価を得たのは、主に先読みが最も短い 3 手の場合と最も長い制限なしの場合となった。

先読み 3 手・制限なしの場合のデータをさらに 1 日目、2 日目で分類した結果、

- 先読み 3 手の場合は 1 日目
- 先読み制限なしの場合は 2 日目

の方がよりグループ A からの評価が高いことが分かった。付録 D で述べるように、1 日目と 2 日目では GUI の設定に差があり 1 日目の GUI では全ての選択肢 (最大 7 種) を起点とした進行図を閲覧可能であるのに対し、2 日目の GUI では起点となる選択肢を二つに制限した。そのため、2 日目は被験者が見られる予想図の数が 1 日目の約 $\frac{1}{3}$ となる。

そのため、「1 日目・先読み 3 手の場合」と「2 日目・先読み制限なし」の場合に被験者が受け取る情報量は近いと推測される。

また、データを「被験者のグループ・日にち・先読み手数」によって分類し、「振り返りによって AI の意図を掴むことができたと感じますか」という質問に対する評価 (以下把握満足度と表記) の降順に並べた直した結果を表 4.8 に示す。

表 4.8: 把握満足度

グループ	日	先読み手数	把握満足度
B	2	5	4.67
B	2	7	4.00
A	1	制限なし	3.50
A	2	制限なし	3.50
B	1	3	3.50
B	1	制限なし	3.33
A	1	3	3.33
...			
A	2	3	1.75
B	1	3	1.50

グループ A のデータを日にちと先読み手数で分けた場合最も把握満足度が高いのは「2 日目・先読み制限なし」、次いで「1 日目・先読み制限なし」、

目・先読み3手」となった。最も情報が少ない「2日目・3手」はグループAの全8パターン中最下位となった。

グループBに対しても同様に「振り返りによってAIの意図を掴むことができたと感じますか」への評価を集計した結果、最も評価が高いのは「2日目・5手」、次いで「2日目・5手」、「2日目・7手」となった。

また、付録Aより提案手法が示す1組の状態 s 、行動 a について示す分岐の数 n の平均は ため、比較手法が示す情報量は提案手法の $?/?$ となる。そのため提示する情報量が大きい程評価が高くなるわけではなく、手法ごとに被験者が適切と感じる情報量が存在すると推測される。

以上の考察を踏まえて先読みを「1~5」として再実験を行った。システム実験では補助として提示した訪問回数、局面評価に注目する被験者が多く見られたため、訪問回数「count」の表示を廃止した。結果は以下のようになった。

第5章

結論

本論文では決定木から複数の進行図を取り出し提示することによる状態 s に対する判断 a の可視化を試みた。

結果として、従来の可視化手法の前提となる最も可能性の高い単一の分岐を取り出す手法 (以下比較手法と表記) よりも高い予測性能とユーザーによる主観評価を得た。

今後は

- 提案手法による人間同士や人間と AI の対戦データに対する予測精度の調査
- より汎用度の高い特徴による最終盤面のグループ化
- AI の判断 a との比較に用いられる判断 \bar{a} のより効果的な選定

に取り組みたい。

謝辞

本研究を行うにあたり親身に相談に乗っていただき、ご指導してくださった萩原将文教授、ならびに共に問題解決、議論、相談、および実験に付き合ってくださいました研究室の先輩方、同期の皆様、実験に参加してくださった大学の友人達に深く感謝いたします。誠にありがとうございました。

参考文献

- [1] et al. Silver David. “A general reinforcement learning algorithm that masters chess, shogi and Go through self-play”. In: *Science* 362.6419 (2018).
- [2] Andreas Blattmann Robin Rombach, Patrick Esser Dominik Lorenz, and Björn Ommer. “High-resolution image synthesis with latent diffusion models”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (2021).
- [3] Jeff Wu Long Ouyang et al. “Training language models to follow instructions with human feedback”. In: *Advances in Neural Information Processing Systems* 35 (2022).
- [4] “G7 Hiroshima Leaders’ Communiqué”. In: (2023). URL: <https://www.g7hiroshima.go.jp/en/documents/> (2024 年 1 月 15 日確認).
- [5] “新しい資本主義のグランドデザイン及び実行計画 2023 改訂版”. In: (2023), pp. 27–29. URL: https://www.cas.go.jp/jp/seisaku/atarashii_sihonsyugi/pdf/ap2023.pdf (2024 年 1 月 15 日確認).
- [6] Richard S. Sutton and Andrew G. Barto. “reinforcement learning”. In: (2018), pp. 251–272.
- [7] et al. Mnih Volodymyr. “Playing atari with deep reinforcement learning”. In: *arXiv preprint arXiv* 1312.5602 (2013).
- [8] et al. Hessel Matteo. “Rainbow: Combining improvements in deep reinforcement learning”. In: *Proceedings of the AAAI conference on artificial intelligence* 32.1 (2018).

-
- [9] et al. SILVER David. “Mastering the game of Go with deep neural networks and tree search”. In: *nature* 529.7587 (2016).
- [10] T. Romstad, M. Costalba, and et al. J. Kiiski. “A strong open source chess engine”. In: (). URL: <https://stockfishchess.org/> (2024 年 1 月 15 日 確認).
- [11] T. Yamaoka. “DeepLearningShogi”. In: (). URL: <https://github.com/TadaoYamaoka/DeepLearningShogi> (2024 年 1 月 15 日 最).
- [12] Bo Zhou. “AlphaZero baseline - ConnectX”. In: (2020). URL: <https://github.com/PaddlePaddle/PARL/tree/develop/benchmark/torch/AlphaZero> (2024 年 1 月 15 日 確認).
- [13] Doshi-Velez, Finale, and Been Kim. “Towards a rigorous science of interpretable machine learning”. In: *arXiv preprint arXiv* 1702.08608 (2017).
- [14] Tobias Huber et al. “Local and Global Explanations of Agent Behavior: Integrating Strategy Summaries with Saliency Maps”. In: *Artificial Intelligence* 301.103571 (2021).
- [15] Hou, Xiaodi, and Liqing Zhang. “Saliency detection: A spectral residual approach”. In: *2007 IEEE Conference on computer vision and pattern recognition* (2007).
- [16] et al Selvaraju Ramprasaath R. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization”. In: *Proceedings of the IEEE international conference on computer vision* (2017).
- [17] et al Pang Wei Koh Kai-Siang Ang. “On the accuracy of influence functions for measuring group effects”. In: *arXiv preprint arXiv* 1711.11279 (2017).
- [18] et al. McGrath Thomas. “Acquisition of Chess Knowledge in AlphaZero”. In: *Proceedings of the National Academy of Sciences* 119.47 119.47 (2022).
- [19] et al. Zeev Fine Ofer Shamai. “DecodeChess”. In: (2017). URL: <https://decodechess.com/> (2024 年 1 月 15 日 確認).

- [20] Anurag Koul Sam Greydanus and Alan Fern Jonathan Dodge. “Visualizing and Understanding Atari Agents”. In: *International conference on machine learning* (2018).
- [21] Yuanfeng Pang and Takeshi Ito. “Visualizing and Understanding Policy Networks of Computer Go”. In: *Journal of Information Processing* 29 (2021).
- [22] Swabha Swayamdipta Alon Jacovi, Yanai Elazar Shauli Ravfogel, and Yoav Goldberg Yejin Choi. “Contrastive Explanations for Model Interpretability”. In: *arXiv preprint arXiv* 2103.01378 (2021).
- [23] Utkarsh Soni Aditi Mishra and Chris Bryan Jinbin Huang. “Why? Why not? When? Visual Explanations of Agent Behaviour in Reinforcement Learning”. In: *arXiv preprint arXiv* 2014.02818v2 (2021).
- [24] Rahul Nair Jasmina Gajcin, Radu Marinescu Tejaswini Pedapati, and Ivana Dusparic Elizabeth Daly. “Contrastive Explanations for Comparing Preferences of Reinforcement Learning Agents”. In: *arXiv preprint arXiv* 2112.09462 (2021).
- [25] Lisa Torrey and Matthew Taylor. “Teaching on a budget: Agents advising agents in reinforcement learning”. In: *In Proceedings of the 2013 international conference on Autonomous agents and multi-agent systems* (2013).
- [26] Ece Kamar Ofra Amir and Barbara J. Grosz Andrey Kolobov. “Interactive teaching strategies for agent training”. In: *International Joint Conferences on Artificial Intelligence* (2016).
- [27] Xian Wu Wenbo Guo and Xinyu Xing Usman Khan. “EDGE: Explaining Deep Reinforcement Learning Policies”. In: *Advances in Neural Information Processing Systems* 34 (2021).

- [28] David Wu Andrew Lee and Mike Lewis Emily Dinan. “Improving Chess Commentaries by Combining Language Models with Symbolic Reasoning Engines”. In: *arXiv preprint arXiv* 2212.08195 (2022).
- [29] Simon Viennot¹ Kokoro Ikeda¹ and Naoyuki Sato¹. “Detection and labeling of bad moves for coaching go”. In: *2016 IEEE Conference on Computational Intelligence and Games (CIG)* (2016).
- [30] Masahiko Osawa Vincent Richard and Michita Imai. “Determining Strategies behind Moves in the Game of Go”. In: *Cloud Network Robotics* 117.95 (2017).
- [31] James Dow Allen. “The Complete Book of Connect 4”. In: (2010).
- [32] Victor Allis. “A Knowledge-based Approach of Connect-Four”. In: (1988).
- [33] John Tromp. “Connect-4 Data Set”. In: *UC Irvine Machine Learning Repository* (1995). URL: <https://archive.ics.uci.edu/dataset/26/connect+4>(2024 年 1 月 15 日確認).
- [34] Peter Cnудde. “1k connect4 validation set”. In: *Kaggle* (2020). URL: <https://www.kaggle.com/petercnudde>(2024 年 1 月 15 日確認).
- [35] Peter Cnудde. “Scoring connect-x agents”. In: *Kaggle* (2020). URL: <https://www.kaggle.com/code/petercnudde/scoring-connect-x-agents/notebook>(2024 年 1 月 15 日確認).

付録 A

データ実験の詳細

A.1 使用したモデルの詳細

第三章で述べたとおり使用した対戦データは弱い AI を先番とし、強い AI を後手としている。AI の強さは一手ごとの探索を行う時間 (time) と付録 C で述べる C_{puct} の値によって調整した。time と C_{puct} はいずれも値が大きい程モデルは強くなると考えられる。対戦データ生成時のパラメータは表 A.1 の幅からゲームごとにランダムな値を採用した。これはパラメータの値を変化させることでゲームデータに多様性を持たせるためである。

表 A.1: 対戦データのパラメータ

モデル	強	弱
time	3-5	0-2
C_{puct}	0.8-1	0-0.5

A.2 対戦結果の詳細

2000 ゲームのうち 1983 ゲームは強い AI(後番) の勝利となった。また、ゲームごとの手数は 75% のゲームが 36 手以内で終了している。図 A.1 にゲームの終了手数の累計グラフを示す。

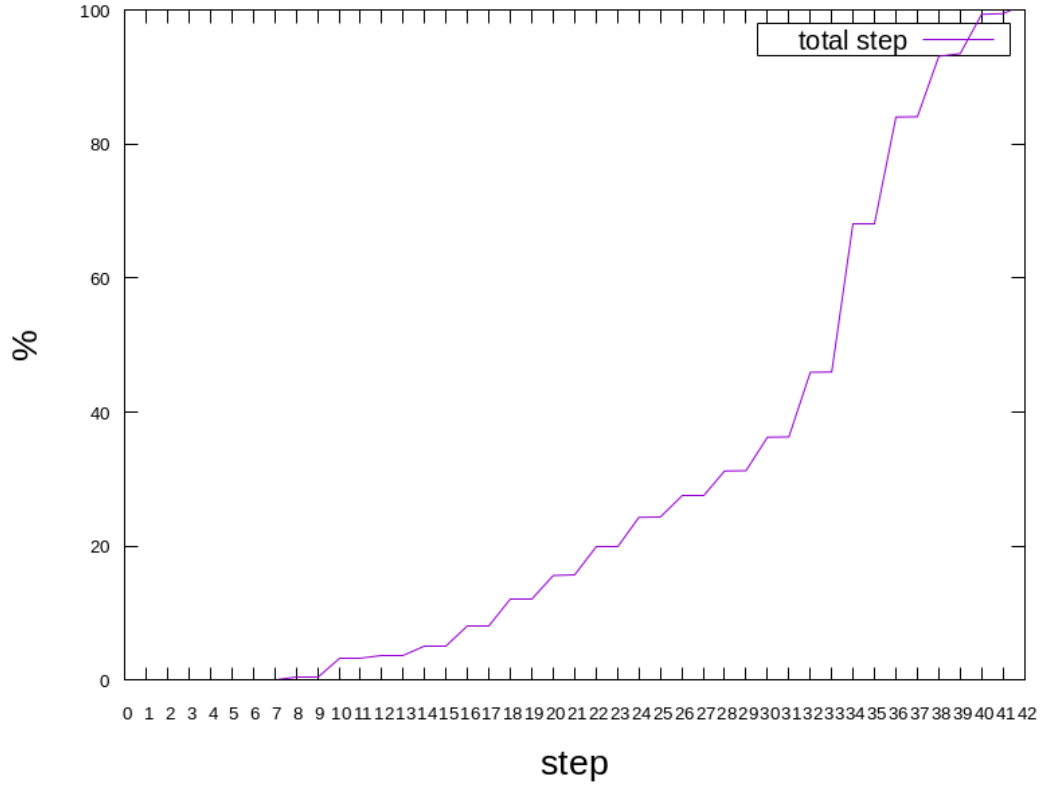


図 A.1: 終了手順の分布

A.3 評価指標の詳細

本論文が提案する提案指標 (group count, stone count) の計算において、盤面の座標は図 A.2 のように定められる。ゲーム終了状態には図 A.3 のように 4 つ以上連続してつながっている石の座標 F_s (fatal stone の集合) とその組み合わせ F_g (fatal group の集合) を記録する。下の図の盤面は 17, 18, 19, 20, 24, 31, 38 の 7 つの fatal stone と $[17, 18, 19, 20]$, $[17, 24, 31, 38]$ の二つの fatal group を持つ group count(C_g), stone count(C_s) は実際のゲームにおける fatal group と fatal stone の集合 (それぞれ R_s, R_g とする) と AI の予測による fatal stone と fatal group の集合 (F_g, F_s) を比較する指標である。どちらも値が高ければ高い程予測の精度が高いことを表す。




図 A.2: 盤面の座標番号

A.3.1 group count

fcount は fatal group の精度を示す二値 (0 または 1) の指標である。

$$C_g = 1 \text{ If } F_g \cap R_g \neq \phi \text{ Else } 0 \quad (\text{A.1})$$


例外として $R_g = \phi$ (引き分け) の場合, F_g も空集合であるならば group count は 1 となる。

A.3.2 stone count

stone count は fatal stone の精度を示す。stone count の値域は $[0, 1]$ である。

(Count() は集合の要素数を数える関数)

$$\text{stone count} = \min\left(\frac{\text{Count}(F_s \cap R_s)}{4}, 1\right) \quad (\text{A.2})$$



Fatal Stone: $\{17, 18, 19, 20, 24, 31, 38\}$

Fatal Group: $\{[17, 18, 19, 20], [17, 24, 31, 38]\}$

図 A.3: fatalStone と fatalGroup

例外として $R_s = \phi$ (引き分け) の場合, F_s も空集合であるならば stone count は 1 となる。

A.4 データ実験における提案指標の計測

1. 比較手法: 付録?で述べた決定木の走査によりたどり着いた F_s, F_g によって stone count, group count を計算した
2. 提案手法: 第三章で述べたアルゴリズムによって収集された最終状態の集合 $S = \{s_{edge_1}, s_{edge_2}, \dots, s_{edge_{kl}}\}$ を指標ごとにグループ化する。

- group count: fatal group によって S をグループ化してできた集合 $\{S_{g_1}, S_{g_2}, \dots, S_{g_n}\}$ (S_{g_i} は組み合わせ g_i が fatal group となっている盤面の集合) を要素が多い順に二つ取り出す。抽出された二つの集合 $\{S_{g_{m_1}}, S_{g_{m_2}}\}$ における $\{g_{m_1}, g_{m_2}\}$ で構成される集合を F_g とし、group count を計算した。
- stone count: g_{m_1} を F_s とし、stone count を計算した。

A.5 データ実験に使用したモデルの詳細

第 4 章に記載した表 4.1 の結果を求める際に用いたモデルのパラメータを表 A.2 に示す。

表 A.2: データ実験:使用モデルのパラメータ

パラメータ名	値
time	対戦時の後番のモデルと同じ
C_{puct}	対戦時の後番のモデルと同じ
k (提案手法のみ)	4
l (提案手法のみ)	2

表 A.2 の通り、対戦データが生成された際のモデルのパラメータを使用している。そのため本手法はモデルの構造とパラメータの値へのアクセスが可能な場合を想定したホワイトボックス的アプローチの実験であると言える。モデルの time, C_{puct} の値を固定して同様の手法を適用した場合の実験結果を A.7 で示す。

A.6 末尾のグループ化

提案手法は予想図とその予想図に至る分岐 (両方を合わせて進行図と記載) を抽出する。図 A.4 は分岐を末尾の 3 手で 2 つのグループに再編する様子を表している。(ここでは分岐は行動 a の連続として表している) 取り出された分岐を

収集された分岐

[1, 2, 3, 4, 5]
 [1, 2, 3, 3, 3, 4, 5]
 [1, 5, 7, 9, 8, 3, 4, 5]
 [1, 6, 2, 7, 5, 2, 5, 7]
 [1, 5, 3, 8, 5, 2, 5, 7]

再グループ化

[1, 2, 3, 4, 5]
 [1, 2, 3, 3, 3, 4, 5]
 [1, 5, 7, 9, 8, 3, 4, 5]
 [1, 6, 2, 7, 5, 2, 5, 7]
 [1, 5, 3, 8, 5, 2, 5, 7]

図 A.4: 再グループ化

末尾の3手の選択でさらにグループ化した結果、元の分岐の数と再グループ化された分岐の数の平均は表 A.3 のようになった。結果として、取り出された分岐のうち、平均約 2~3 つの分岐において末尾の3手が共通する傾向にあることがわかった。

表 A.3: 再グループ化した際の分岐の数

手数 (盤面数, 補間の有無)	再グループ化前の分岐数 (平均)	再グループ化後の分岐数 (平均)
19-24(9862, 無)		0.44
19-24(9862, 有)		0.44
13-24(21022, 無)	6.95	3.08
13-24(21022, 有)	12.93	4.51
全て (61049, 無)		
全て (61049, 有)		

A.7 グレーボックス的手法

モデルのパラメータを固定し、再び第四章のデータ実験を行った。パラメータの値を固定しているため、本実験はモデルの具体的なパラメータの値へのアクセスが不可能な場合にも適用可能なグレーボックス的手法であると言える。

表 A.4: データ実験 (追加):使用モデルのパラメータ

パラメータ名	値
time	5
C_{puct}	1
k (提案手法のみ)	4
l (提案手法のみ)	2

実験の結果は表 A.5 のようになった。第四章に記載したホワイトボックス的手法と同様に提案手法は group count において比較手法より高い値を示した。

表 A.5: 実験結果:データ実験

	group count		stone count	
手数 (盤面数, 補間の有無)	提案手法	比較手法	提案手法	比較手法
19-24(9862, 無)	0.60	0.44	0.61	0.63
19-24(9862, 有)	0.63	0.44	0.61	0.63
13-24(21022, 無)	0.53	0.37	0.55	0.56
13-24(21022, 有)	0.55	0.37	0.55	0.56

付録 B

各種アルゴリズムの詳細

B.1 提案手法のアルゴリズム

提案手法のアルゴリズムの疑似コードを Algorithm3、Algorithm4 に示す。

B.2 比較手法のアルゴリズム


比較手法の疑似コードを Algorithm 5 に示す。疑似コード中の `Traverse()` は Algorithm4 と同一である。

B.3 提案手法におけるニューロ補間

第四章におけるデータ実験、システム実験ではいずれも手法のニューラルネットワークによる補間を行っている。第四章で示した疑似コードでは未探索のノードにたどり着いた際は走査を終了する。ニューラルネットワークによる補間とはこの場合、方策 $P(s, a)$ で訪問回数 $N(s, a)$ を代用し走査を継続することである。Algorithm6 にニューロ補間を行う場合の疑似コードを示す（変更部分に下線）。比較手法に対してニューロ補間を行う場合も同様に `Traverse()` のコードを変更する。

Algorithm 3 提案手法のアルゴリズム (part1)

```

1:  $t$ : 手法を適用する探索木
2:  $T$ : 状態遷移関数
3:  $l$ : 盤面の収集を行う手数
4:  $k$ : 一度に集める盤面の数
5:  $\zeta(s, s')$ : ノード  $s$  から  $s'$  までの軌道
6: function MYALGORITHM( $s_{start}, a, l, k$ )
7:    $s_{now} \leftarrow s_{start}$ 
8:    $a_{now} \leftarrow a$ 
9:    $Z_0 \leftarrow \text{COLLECTBOARDS}(s_{now}, a_{now}, l, k)$ 
10:  ( $Z_0 = \{\zeta(s_{start}, s'_1), \dots, \zeta(s_{start}, s'_{kl})\}$ )
11:   $Z \leftarrow$  empty list
12:  for each  $\zeta(s_{start}, s'_i)$  in  $Z_0$  do
13:     $\zeta(s_{start}, s_{edge_i}) \leftarrow \text{TRAVERSE}(s'_i, \zeta(s_{start}, s'_i))$ 
14:     $\zeta(s_{start}, s_{edge_i})$  を  $Z$  の末尾に追加
15:  end for
16:  収集された終了状態の集合  $S(= \{s_{edge_1}, s_{edge_2}, \dots, s_{edge_{kl}}\})$  を任意の共通
    項  $c$  で副集合  $\{S_1, S_2, \dots, S_q\}$  に分割する
17:  最も要素数の多い副集合  $S_{max}$  中の各要素  $\{s_{e_1}, s_{e_2}, \dots, s_{e_u}\}$ 
18:  に対応する軌道の集合  $Z_{max}(= \{\zeta(s_{start}, s_{e_1}), \zeta(s_{start}, s_{e_2}), \dots, \zeta(s_{start}, s_{e_u})\})$ 
    を保存
19:    $Z_{max}$ 
20: end function

```

Algorithm 4 提案手法のアルゴリズム (part2)



```

1: function COLLECTBOARDS( $s, a, l, k$ )
2:    $s_{now} \leftarrow T(s, a)$ 
3:    $Z \leftarrow$  empty queue
4:   if  $s$  が未探索のノード ( $N(s) = 0$ ) または終了状態のとき then  $\hookrightarrow Z$ 
5:     end if
6:   訪問回数  $N(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
7:   for each  $a_i$  in  $\alpha$  do
8:      $s_{next_i} \leftarrow T(s_{now}, a_i)$ 
9:      $\zeta(s_{now}, s_{next_i}) (= \{s_{now}, a_i, s_{next_i}\})$  を  $Z$  の末尾に追加
10:  end for
11:  if  $l=1$  then  $\hookrightarrow Z$ 
12:  end if
13:   $i \leftarrow 1$ 
14:  while  $i < l$  do
15:    for each  $\zeta(s_{now}, s_j)$  in  $Z$  do
16:       $\zeta(s_{now}, s_j)$  を  $Z$  からポップ
17:      if  $s$  が未探索のノード ( $N(s) = 0$ ) または終了状態のとき then
18:         $\zeta(s_{now}, s_j)$  を  $k$  回  $Z$  の末尾に追加
19:      continue
20:      end if
21:      訪問回数  $N(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
22:      for each  $a_i$  in  $\alpha$  do
23:         $s_{next_j} \leftarrow T(s_j, a_i)$ 
24:         $\zeta(s_{now}, s_{next_i}) (= \zeta(s_{now}, s_j).append(a_i, s_{next_i}))$  を  $Z$  の末尾に追加
25:      end for
26:    end for
27:  end while  $\hookrightarrow Z (= \{\zeta(s_{start}, s'_1), \dots, \zeta(s_{start}, s'_k)\})$ 
28: end function
29: function TRAVERSE( $s, \zeta(s_{start}, s)$ )
30:    $s_{now} \leftarrow s$ 
31:    $\zeta_r \leftarrow \zeta(s_{start}, s)$ 
32:   while  $s_{now}$  が探索済みかつ終了状態でない do
33:      $a_t \leftarrow \operatorname{argmax}_a N(s_{now}, a)$ 
34:      $s_n \leftarrow T(s_{now}, a_t)$ 
35:      $\zeta_r.append(a_t, s_n)$ 
36:      $s_{now} \leftarrow s_n$ 
37:   end while  $\hookrightarrow \zeta_r$ 
38: end function

```

Algorithm 5 比較手法のアルゴリズム

```

1:  $t$ : 手法を適用する探索木
2:  $T$ : 状態遷移関数
3:  $\zeta(s, s')$ : ノード  $s$  から  $s'$  までの軌道
4: function COMPAREALGORITHM( $s, a$ )
5:    $s_n \leftarrow T(s, a)$ 
6:    $\zeta(s, s_n) \leftarrow \{s, a, s_n\}$ 
7:    $\zeta \leftarrow s_n, \zeta(s, s_n)$    $\zeta$ 
8: end function
9: function TRAVERSE( $s, \zeta(s_{start}, s)$ )
10:   $s_{now} \leftarrow s$ 
11:   $\zeta_r \leftarrow \zeta(s_{start}, s)$ 
12:  while  $s_{now}$  が探索済みかつ終了状態でない do
13:     $a_t \leftarrow \operatorname{argmax}_a N(s_{now}, a)$ 
14:     $s_n \leftarrow T(s_{now}, a_t)$ 
15:     $\zeta_r.append(a_t, s_n)$ 
16:     $s_{now} \leftarrow s_n$ 
17:  end while   $\zeta_r$ 
18: end function

```

Algorithm 6 提案手法のアルゴリズム (ニューロ補間あり)part1


```

1: function COLLECTBOARDS( $s, a, l, k$ )
2:    $s_{now} \leftarrow T(s, a)$ 
3:    $Z \leftarrow$  empty queue
4:   if  $s$  が終了状態のとき then  $\hookleftarrow Z$ 
5:   end if
6:   if  $s$  が未探索のとき then
7:     方策  $P(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
8:   else
9:     訪問回数  $N(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
10:  end if
11:  for each  $a_i$  in  $\alpha$  do
12:     $s_{next_i} \leftarrow T(s_{now}, a_i)$ 
13:     $\zeta(s_{now}, s_{next_i}) (= \{s_{now}, a_i, s_{next_i}\})$  を  $Z$  の末尾に追加
14:  end for
15:  if  $l=1$  then  $\hookleftarrow Z$ 
16:  end if
17:   $i \leftarrow 1$ 
18:  while  $i < l$  do
19:    for each  $\zeta(s_{now}, s_j)$  in  $Z$  do
20:       $\zeta(s_{now}, s_j)$  を  $Z$  からポップ
21:      if  $s$  終了状態のとき then
22:         $\zeta(s_{now}, s_j)$  を  $k$  回  $Z$  の末尾に追加
23:        continue
24:      end if
25:      if  $s$  が未探索のとき then
26:        方策  $P(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
27:      else
28:        訪問回数  $N(s)$  から上位  $k$  の行動  $\{a_1, a_2, \dots, a_k\} (= \alpha)$  を取り出す
29:      end if
30:      for each  $a_i$  in  $\alpha$  do
31:         $s_{next_j} \leftarrow T(s_j, a_i)$ 
32:         $\zeta(s_{now}, s_{next_i}) (= \zeta(s_{now}, s_j).append(a_i, s_{next_i}))$  を  $Z$  の末尾に追加
33:      end for
34:    end for
35:  end while  $\hookleftarrow Z (= \{\zeta(s_{start}, s'_1), \dots, \zeta(s_{start}, s'_{k'})\})$ 
36: end function

```

Algorithm 7 提案手法のアルゴリズム (ニューロ補間あり)part2

```

1: function TRAVERSE( $s, \zeta(s_{start}, s)$ )
2:    $s_{now} \leftarrow s$ 
3:    $\zeta_r \leftarrow \zeta(s_{start}, s)$ 
4:   while  $s_{now}$  が終了状態でない do
5:     if  $s$  が未探索のとき then
6:        $a_t \leftarrow \arg\max_a P(s_{now}, a)$ 
7:     else
8:        $a_t \leftarrow \arg\max_a N(s_{now}, a)$ 
9:     end if
10:     $s_n \leftarrow T(s_{now}, a_t)$ 
11:     $\zeta_r.append(a_t, s_n)$ 
12:     $s_{now} \leftarrow s_n$ 
13:  end while   $\zeta_r$ 
14: end function

```

B.4 システム実験における提案手法の変更

システム実験では画面の左下に盤面 s の訪問回数 $N(s)$ と局面評価 $V(s, a)$ を表示する。このとき $V(s, a)$ の絶対値 (どちらのプレイヤーの勝利に近い) と予想図の勝敗が異なる場合、ユーザーの混乱を招く可能性がある。そのため、提案手法では勝敗が $V(s, a)$ の絶対値と一致する軌道を表示するように修正を施した。システム実験用に修正された疑似コードは Algorithm:8 となる。(下線が変更部分) また、提案手法により収集した最終盤面 $S = \{s_{edge_1}, s_{edge_2}, \dots, s_{edge_{k_l}}\}$ は最終的に 4 つ以上連続してつながっている石の組み合わせ (fatal group) でグループ化し、最も要素数が多い集合の道筋をユーザーに提示した。

Algorithm 8 提案手法のアルゴリズム (システム実験)

```

1: function TRAVERSE( $s, \zeta(s_{start}, s)$ )
2:    $\zeta(s_{start}, s)$  から  $s_{start}$  の次の行動  $a$  を取り出す
3:    $v \leftarrow V(s, a)$ 
4:    $s_{now} \leftarrow s$ 
5:    $\zeta_r \leftarrow \zeta(s_{start}, s)$ 
6:   while  $s_{now}$  が終了状態でない do
7:     if  $s$  が未探索のとき then
8:        $a_t \leftarrow \operatorname{argmax}_a P(s_{now}, a)$ 
9:     else
10:       $a_t \leftarrow \operatorname{argmax}_a N(s_{now}, a)$ 
11:    end if
12:     $s_n \leftarrow T(s_{now}, a_t)$ 
13:     $\zeta_r.append(a_t, s_n)$ 
14:     $s_{now} \leftarrow s_n$ 
15:  end while
16:  if  $v$  と  $V(s_{now})$  の絶対値が異なるとき then  $\leftarrow \text{null}$ 
17:  end if  $\zeta_r$ 
18: end function

```

付録C

alphazero_baseline

C.1 ニューラルネットワーク

モデルの構成は以下である。alphazero_baseline における選択肢は列の数と等しい7であるため、 1×7 の行列となる。例えば方策が $\{0, 0.1, 0.2, 0, 0, 0.7, 0.8\}$ であるとき、方策中の最も大きい成分は7番目の0.8であるため、プレイヤーは次に7列目を選択する事が推奨される。また、モデルの訓練過程は以下のステップの繰り返しによって構成されている。使用したテストデータ [34] は - 木探索による connect4 の解から生成されている [35]。

1. 500 ゲーム分の自己対戦を行う
2. 自己対戦によって収集した盤面を入力としてネットワークを訓練
3. ネットワークを教師データによって評価
4. 新しいネットワークを用いた AI と訓練前の最善のネットワークを用いた AI による対戦を 50 ゲーム分行い6割以上の勝率を記録した場合、新しいネットワーク最善のネットワークとして保存する

本論文の第3章におけるシステム実験で用いた「強い AI」のニューラルネットワークは上記をステップを 200 エポック分実行して訓練されたモデルを使用している。

また、上記の 2. におけるネットワーク訓練時のパラメータの値は以下を用いた。

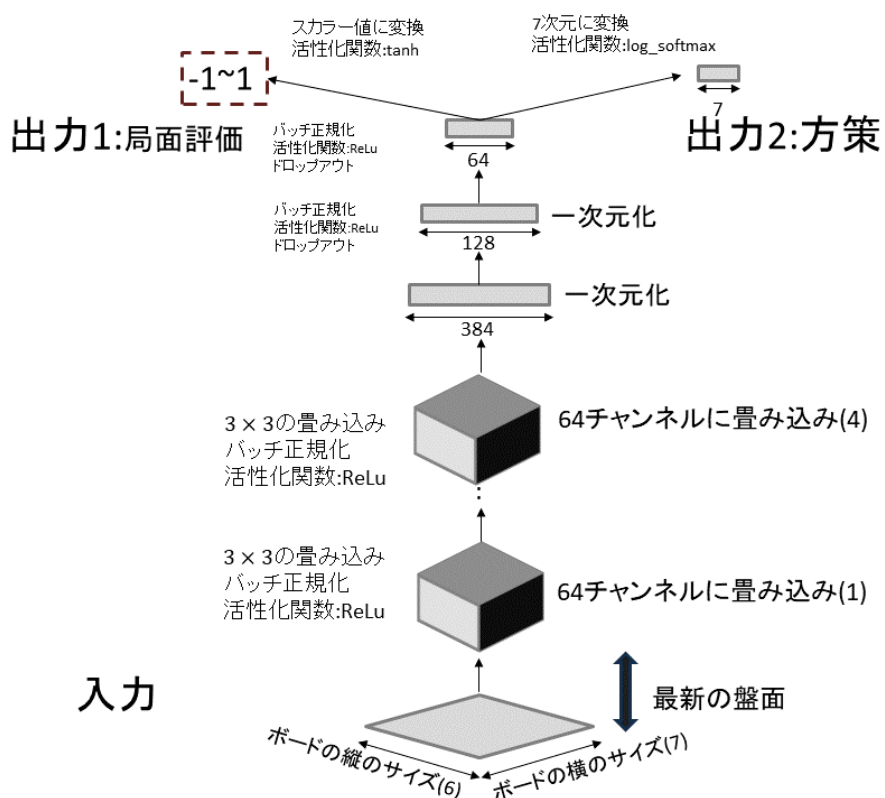


図 C.1: alphazero_baseline ネットワークの構成

表 C.1: ネットワーク訓練時のパラメータ名と値

パラメータ名	値
学習率 (lr)	0.001
dropout	0.3
epochs	5
batch_size	64
num_channels	64

C.2 alphazero_baseline のパラメータ更新

alphazero_baseline のパラメータ更新は第二章で述べた手順とほぼ同一であるが PUCT スコア $U(s, a)$ の定義における C_{cpuct} はハイパーパラメータである。

($N(s)$, $N(s, a)$ はそれぞれ s , (s, a) に対して探索を行った回数)


$$U(s, a) = C_{\text{cpuct}} P(s, a) \frac{\sqrt{N(s)}}{1 + N(s, a)} \quad (\text{C.1})$$

$Q(s, a)$ は以下のように更新される。 $(s_c$ は現在の探索ノード s から見た最も *PUCT* スコア $U(s, a)$ と $Q(s, a)$ の和の高い子ノード)


$$Q(s, a) = \frac{N(s, a)Q(s, a) + V(s_c)}{N(s, a) + 1} \quad (\text{C.2})$$

Algorithm 9 PV-MCTS in alphazero-baseline (変更部分)

```

1:  $t$ : 決定木
2:  $T$ : 遷移関数
3:  $N(s, a)$ :  $(s, a)$  の組み合わせを探索した回数
4:  $Q(s, a)$ : 行動価値関数 ( $\text{Explore}(s)$  の平均)
5:  $W(s, a)$ : 行動価値の総和 ( $W(s, a) = Q(s, a)N(s, a)$ )
6:  $P(s, a)(= P(s_n), s_n = T(s, a))$ :
7: ニューラルネットワークから出力された方策
8:  $V(s, a)(= V(s_n), s_n = T(s, a))$ :
9: ニューラルネットワークから出力された局面評価
10: function TREEPOLICY( $s$ )
11:   if  $s$  が探索されていない子ノードを持つとき then
12:      $s_c \leftarrow T(s, a)$  ( $s_c$  は未探索のノード)
13:     INITNODE( $s_c$ )
14:       $a$ 
15:   else
16:     以下の PUCT スコア  $U(s, a)$  を計算
17:     
$$U(s, a) = C_{\text{puuct}} P(s, a) \frac{\sqrt{N(s)}}{1+N(s, a)}$$

18:     
$$(N(s) = \Gamma N(s, a))$$

19:     以下のように  $a$  を求める
20:      $a = \arg\max_a (Q(s, a) + U(s, a))$ 
21:       $a$ 
22:   end if
23: end function
24: function BACKPROPAGATE( $\zeta, G$ )
25:   for each node-action pair  $(s, a)$  in  $\zeta$  do
26:      $N(s, a) \leftarrow 0$ 
27:      $W(s, a) \leftarrow 0$ 
28:      $Q(s, a) \leftarrow 0$ 
29:   end for
30: end function
31: function INITNODE( $s$ )
32:   for each action  $a$  from  $s$  do
33:      $N(s, a) \leftarrow N(s, a) + 1$ 
34:      $W(s, a) \leftarrow W(s, a) + G$ 
35:     
$$Q(s, a) \leftarrow \frac{N(s, a)Q(s, a) + V(s_c)}{N(s, a) + 1}$$

36:      $(s_c = T(s, a))$ 
37:   end for
38: end function

```

付録 D

システム実験の詳細

システム実験では全三回にわたる実験を行い、被験者同士の対戦を行う第三回以外の二回は被験者が AI との対戦と AI を用いた振り返りを行う。第四章と同様に 3 回 1 セットの実験のうち、前半二回を第一段階・後半一回を第二段階と呼ぶ。以下で被験者のデータの詳細を述べ、それから実験設定や結果の詳細を段階ごとに述べていく。

D.1 被験者のデータ

実験対象者は計 22 人の 10 代-20 代学生 (男性 17 名:女性 5 名) であり、表 D.1 に示す各種の事前質問 (1 ~ 5 の値で答える) の結果は以下となった。ボードゲームの経験を問う質問に関しては 1 を「1 年に 1 回程プレイする」程度、5 を「週に 2,3 回以上プレイする」程度と定めた。connect4 の経験を問う質問に関しては 1 を「connect4 を知らない」程度、5 を「週に 2,3 回以上プレイする」程度と定めた。また、機械学習・強化学習の知識を問う質問に関しては 1 を「言葉を聞いたことがある」程度、5 を「機械学習についての入門書を読んだり、授業を受けたことがある」程度と定めた。また、被験者には先述の Allis[32] による 9strategy をはじめとした connect4 の知識的解法をネット検索等の手段で調べないよう要請した。

表 D.1: 事前質問項目:システム実験

質問	回答の平均
ボードゲームの経験はどれくらいありますか	2.18
connect4(ゲーム) の経験はどれくらいありますか	1.64
機械学習に対する知識はどれくらいありますか	3.59
強化学習に対する知識はどれくらいありますか	3.23

D.2 第一段階

第一段階は AI との対戦とその振り返りによって構成されている。振り返りモードでは表示する予想図の手数、AI の強さを被験者ごとに変更しつつ実験を行った。予想図の手数は $\{3, 5, 7, \text{制限なし (最後まで表示)}\}$ の 4 段階、AI の強さは $\{\text{強, 弱}\}$ の 2 段階を設定した。使用した AI モデル (alphazero_baseline), 提案手法に与えるパラメータを表 D.2 に示す。

表 D.2: AI モデルのパラメータ (システム実験・第一段階)

モデル	強	弱
time	5	1
C_{puct}	1	0.25
k (提案手法のみ)	4	4
l (提案手法のみ)	2	2

また、1 回の実験当たりの制限時間は 7 分とし、実験内の AI との対戦は 2 回までに制限した。これは実戦経験による熟達ではなく支援システムによる学習過程の観察という実験の趣旨に従うためである。

D.2.1 振り返りモード (GUI) の詳細

振り返りモードでは直前の対戦の内容を振り返ることができる。「 i/i 」ボタンを押すことで「一つ先の盤面に進む/戻る」ことができる。また、振り返りを補助する機能として画面左下の「counts」に表示されている盤面 s に対する各

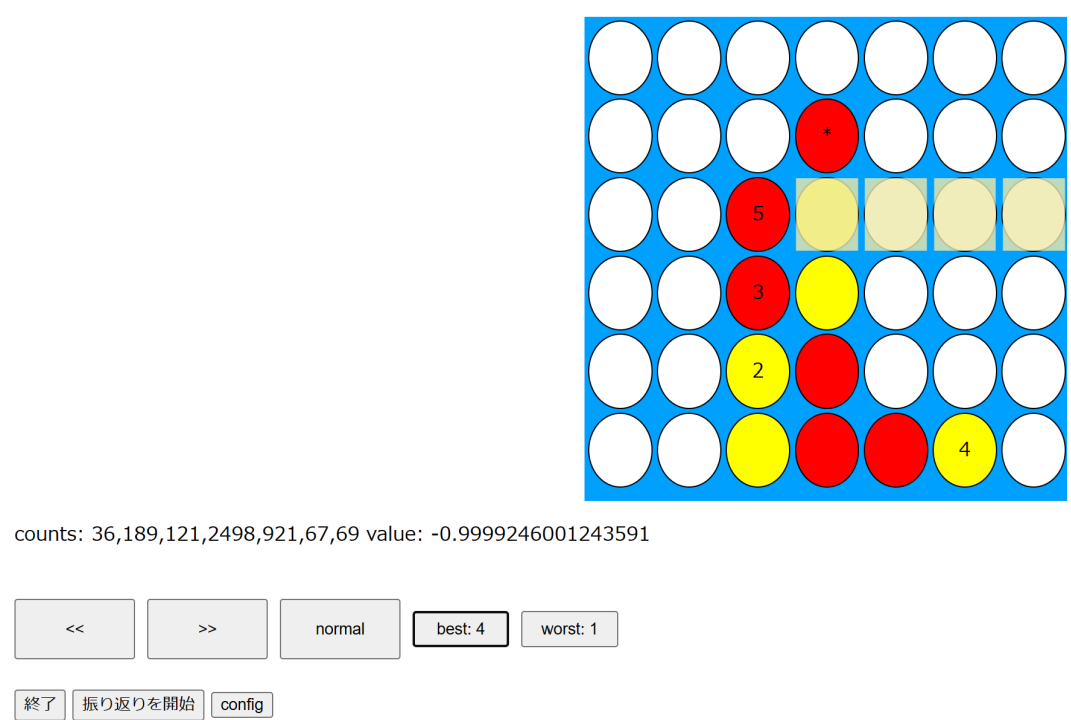


図 D.1: 予想図の提示

行動の訪問回数 $N(s)$, 「value」に局面評価 $V(s)$ を示した。 $N(s)$, $V(s)$ は対戦に使用したモデルから導かれる。数字が書かれているボタンは AI モデル (対戦に使ったモデルと同じ) による予想図を提示するボタンであり、ボタンに描かれた数字と同じ列を選択した場合の予想図を見ることができる。図 D.1 では「4」と描かれたボタンを押した結果、左から 4 番目を選択した場合の予想図が表示されていることがわかる。選択した位置は「*」マークで表示される。想定図中の数字は数字の大きさの順番に石が置かれるという AI の予想を表している。図 D.1 では赤が「*」マークの位置に石を置いた次に黄は左から 3 列目の位置、その次に赤は左から 3 列目に打つことが予測されている。また、図中で色づけられている部分は予想図においてその部分がは四つ以上つながることを示している。赤く色づけられている場合はその部分で赤が 4 つ以上つながると予想されていること、黄色く色づけられている場合はその部分で黄色が 4 つ以上つながると予想されていることを示している。また、提案手法による振り返りが適用されたグループでは提示される予想図が複数となる。そのため図 D.2 に示すよう

に他の想定図を見ることができる「next_prej/pre_traj」が追加される。ここからは第一段階中の一日目、二日目の GUI の違いについて述べる

D.2.2 一日目

一日目は被験者の操作間への慣れを促進するため全ての選択肢に対して予想図表示ボタン（数字ボタン）を設置した。図 D.3 に示すようにこれらのボタンは「traj」ボタンを押すことで出現する。

D.2.3 二日目

二日目は予想図の閲覧を促進するため traj ボタンを廃止し、最も訪問回数 $N(s, a)$ の多い選択肢 a_{max} , 少ない選択肢 a_{min} からの予想図を示すボタンをそれぞれ「best:(列の数字)」「worst:(列の数字)」のラベルで図 D.4 のように表示した。

D.3 第二段階

第二段階は提案手法を用いて振り返りを行ったグループ (A) の被験者と比較手法を用いて振り返りを行ったグループ (B) の被験者の対戦である。一回の実験の中で二人の被験者が手番を入れ変え二回の対戦を行った。制限時間は1ゲーム5分であり、制限時間内に終わらなかったゲームはAIによって判定した。具体的には制限時間が切れた際の盤面 s の AI による局面評価 $V(s)$ の絶対値が0.5以上である場合にはその符号が示すプレイヤーの勝利とし、 $V(s)$ の絶対値が0.5未満である場合は引き分けとする。判定用に使用した AI モデルのパラメータは D.3 に示す。

表 D.3: AI モデルのパラメータ (システム実験・第二段階)

パラメータ名	値
time	0
C_{puct}	1

D.4 質問項目の詳細

質問項目は「タスクの熟達度に関連する質問」((a))と「タスクの楽しさ・面白さに関連する質問」((b))の二つに分けられる。具体的な質問項目は D.4 に記載した。また、二日目は「タスクの楽しさ・面白さに関連する質問」に「一回目と比べて成長したと感じますか」を追加した。

表 D.4: 質問項目:システム実験

質問の種類	質問の内容
タスクの熟達度に関連する質問	対局によって成長したと感みましたか 振り返りによって成長したと感みましたか 振り返りによって AI の意図を掴むことができたと感じますか (二日目のみ) 一回目と比べて成長したと感じますか
タスクの楽しさ・面白さに関連する質問	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか システムにより振り返りが楽しくなったと感じますか

D.5 結果データ

第 4 章では先読みの手数ごとに結果データを集計した。ここでは他の観点から集計されたデータを示す。表 D.5 に先読みの手数を分けずに合計した結果を示す。

表 D.5: 結果:総合

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.55	3.86
	振り返りによって AI の意図を掴むことができたと感じますか	2.73	3.32
	(二回目のみ) 一回目に比べて成長したと感じますか	3.36	4.00
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.05	4.27
	システムにより振り返りが楽しくなったと感じますか	3.86	4.33

また、AI の強さごとに集計した結果を表 D.6、表 D.7 に示す。表 D.6 に強い AI を用いて訓練した被験者のデータ、表 D.7 に弱い AI を用いて訓練した被験者のデータを示す。

表 D.6: 結果:AI の強さ (強い)

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.67	3.82
	振り返りによって AI の意図を掴むことができたと感じますか	2.58	3.55
	(二回目のみ) 一回目に比べて成長したと感じますか	3.00	4.00
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.08	4.64
	システムにより振り返りが楽しくなったと感じますか	3.75	4.50

表 D.7: 結果:AI の強さ (弱い)

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.8	3.33
	振り返りによって AI の意図を掴むことができたと感じますか	3.00	3.00
	(二回目のみ) 一回目に比べて成長したと感じますか	3.80	4.00
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.00	3.80
	システムにより振り返りが楽しくなったと感じますか	4	4.1


また、一日目のデータを表 D.8、二日目のデータを表 D.9 に記載する。

表 D.8: 結果:一日目

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.56	3.78
	振り返りによって AI の意図を掴むことができたと感じますか	3.05	2.94
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.06	4.28
	システムにより振り返りが楽しくなったと感じますか	4.06	4.28

表 D.9: 結果:二日目

質問		主観評価	
質問の種類	質問の内容	A	B
(a)	振り返りによって成長したと感じましたか	3.55	3.91
	振り返りによって AI の意図を掴むことができたと感じますか	2.45	3.64
	(二回目のみ) 一回目に比べて成長したと感じますか	3.36	4.00
(b)	今後も connect4 をプレイするときにこのシステムを使いたいと思いましたか	4.00	4.18
	システムにより振り返りが楽しくなったと感じますか	3.91	4.40



4 5 6 7 next_traj pre_traj close

図 D.2: 提案手法による予想図の提示




図 D.3: 予想図表示ボタン (一目目)




図 D.4: 予想図表示ボタン (二日目)